

基于动态检索增强生成技术的金融信贷风控应用分析

姓名：刘雨鑫 班级：金融 2403 班 学号：2022211478

AI 使用声明：本作业在完成过程中使用了生成式人工智能工具 豆包 辅助进行选题、资料整理、结构设计和语言润色。正文中的观点、案例取舍和最终表述仍需由本人逐句审阅、修订并承担文责。与本次作业相关的原始对话记录应按课程要求以截图或单独 PDF 的形式附在正文之后或另行上传。

一、近三年计算机领域论文选读及其商业应用

（一）论文来源与选题理由

本文选读的计算机领域论文为 Weihang Su、Yichen Tang、Qingyao Ai、Zhijing Wu、Yiqun Liu 于 2024 年发表在 ACL 2024 主会场文集的论文《DRAGIN: Dynamic Retrieval Augmented Generation based on the Real-time Information Needs of Large Language Models》。该文发表于 2024 年 8 月，论文来源为 ACL Anthology，收录于 Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)，页码为 12991-13013，DOI 为 10.18653/v1/2024.acl-long.702。

之所以选择这篇论文，是因为它讨论的检索增强生成技术，也就是 RAG，正好位于当前人工智能应用从“能回答”走向“可验证、可追溯、可落地”的关键位置。普通大语言模型依靠训练阶段形成的参数知识回答问题，优势是语言表达流畅、泛化能力强，但缺点也明显：模型无法实时掌握最新资料，容易把不确定内容说得很肯定，也难以说明答案具体来自哪份文件。金融、法律、审计、企业管理等领域恰恰最怕这种问题，因为这些场景不仅要答案，还要依据、出处、时效性和责任边界。因此，RAG 通过把模型回答和外部知识库、企业文档、政策制度、数据库记录结合起来，成为大模型进入严肃商业场景的重要路径。

（二）论文主要内容介绍

传统 RAG 的基本流程并不复杂：用户提出问题后，系统先到外部文档库中检索相关材料，再把检索结果连同问题一起交给大语言模型生成答案。这个思路看起来合理，但在实际任务中存在两个核心难题。第一，什么时候需要检索并不总是固定的。简单问题可能不需要查资料，复杂问题

可能在回答中途才发现某个环节缺少事实依据。第二，检索什么也不是简单地把用户最后一句话拿去搜索。很多问题的真实信息需求分散在上下文中，尤其是多轮对话、多跳推理、长报告写作等场景，模型当前正在写的句子未必能完整代表它真正缺少的信息。

DRAGIN 这篇论文正是围绕“何时检索”和“检索什么”两个问题展开。论文认为，动态 RAG 不能只依靠静态规则，也不能只把最近几个 token 或最近一句话当作检索查询，而应当根据大语言模型在生成过程中的实时信息需求来决定检索行为。所谓实时信息需求，可以理解为：模型在生成答案时，会在某些位置暴露出不确定、缺知识、需要外部事实支撑的状态。系统如果能识别这种状态，就可以在必要时启动检索；如果还能从完整上下文中提炼出更准确的查询，就能找到更相关的资料。

论文提出的 DRAGIN 框架把检索过程嵌入到生成过程之中。与“先检索、再一次性回答”的普通方式相比，它更像是让模型边写边检查自己是否需要查证。其一，DRAGIN 会判断当前生成状态是否已经出现新的信息需求，从而避免无意义检索。无意义检索不仅浪费算力，也可能把不相关材料引入上下文，反而干扰模型判断。其二，DRAGIN 会根据模型的上下文信息构造更适合检索的查询，而不是机械截取最后一句话。这样做的意义在于，复杂问题常常需要跨句、跨段落理解，真正关键的关键词可能已经出现在更早的上下文里。其三，论文通过多个知识密集型生成数据集进行实验，将 DRAGIN 与已有方法比较，结果显示该框架在相关任务上取得了更好的表现。

从技术思想上看，这篇论文的价值不只是提升问答准确率，而是把 RAG 从一个“固定外挂资料包”的系统，推进到一个“会根据自身需要主动查证”的系统。它所强调的动态性、上下文完整性和信息需求识别，正是大模型应用落地时经常被忽视的部分。很多企业部署大模型时，以为只要把内部文档放进知识库，模型就能稳定回答业务问题。但实际情况是，如果检索触发时机不对、查询构造不准、引用材料不相关，那么系统仍然会出现答非所问、依据错误、解释不充分等问题。DRAGIN 的贡献在于提醒我们：RAG 的关键不只是“接入文档”，而是让模型知道自己什么时候需要文档、需要哪类文档、如何把文档用于当前推理。

（三）该技术在金融和商业领域的可能应用

在金融领域，DRAGIN 代表的动态 RAG 技术最直接的应用，是构建面向银行、券商、保险和资管机构的专业知识助手。金融机构内部有大量制度文件、监管通知、产品说明书、客户合同、风控政策和历史案例，工作人员经常需要在这些材料中快速定位依据。传统搜索工具只能返回文件列表，要求员工自己阅读、比对和总结；普通大语言模型虽然能总结，但如果缺少检索约束，就可能编造政策或误解条款。动态 RAG 则可以在回答过程中自动识别需要查证的部分，把最新制度和原始文件纳入生成过程，并给出可追溯的引用路径。

以商业银行信贷业务为例，客户经理或风控人员在审查一家企业贷款申请时，需要查看企业财务报表、征信记录、工商信息、担保合同、行业数据、银行授信政策以及监管要求。这个过程的信息来源极多，而且文档结构并不统一。动态 RAG 可以先根据任务目标判断需要哪些材料，例如企业偿债能力、现金流真实性、关联交易风险、抵押物合法性等；在生成审查意见时，如果模型发现某个判断缺少依据，就继续检索对应文件，而不是凭常识补全。这样形成的信贷审查报告会更接近真实业务逻辑：每一个风险判断最好都能回到具体数据或条款。

在投资研究领域，动态 RAG 也有应用空间。投研人员每天面对上市公司公告、研报、财报、行业新闻和宏观数据。普通模型可以帮助总结信息，但最大问题是容易忽略时效性和来源可靠性。动态 RAG 可以按照“研究问题-证据检索-观点生成-出处核验”的流程工作：当分析某家公司利润变化时，系统需要优先检索最新财报和公告；当涉及行业政策时，需要调用权威部门文件；当涉及市场预期时，再参考券商研报或新闻材料。这样能够减少把旧信息当新信息、把市场传闻当事实依据的风险。

在其他商业领域，例如企业采购、合同审查、客户服务和内部审计中，DRAGIN 的思路同样有价值。采购部门可以用它比对招标文件、供应商资质和历史价格；法务部门可以用它检索合同条款和法律依据；客服部门可以用它根据产品手册和售后政策回答客户问题；审计部门可以用它从制度、凭证和流程记录中发现异常线索。它们的共同点是：业务回答不能只靠模型“会说”，而要靠模型“会查、会引、会解释”。

不过，这项技术在金融场景落地时也有边界。第一，RAG 并不能自动保证资料本身真实可靠，如果知识库中存在过期制度、错误标签或重复文件，模型仍可能引用错误材料。第二，金融机构的数据涉及客户隐私和商

业秘密，检索系统必须设置严格权限，不能让普通员工查询不该看的客户信息。第三，大模型生成的结果不能直接代替审批结论，尤其在授信、反洗钱、投资建议等高风险场景，应当保留人工复核和责任链条。第四，模型输出需要可审计，系统应保存检索记录、引用材料和生成过程，方便事后追责和改进。

二、金融行业特定岗位及科技赋能设想

（一）岗位选择：商业银行信贷风险分析师

本文关注的金融行业岗位是商业银行信贷风险分析师。这个岗位处于银行风险管理和信贷业务之间，主要任务不是单纯“放贷款”，而是判断贷款对象是否具备还款能力、贷款结构是否合理、担保措施是否有效以及潜在风险是否可控。与前台客户经理相比，信贷风险分析师更强调独立判断和风险识别；与纯技术岗位相比，它又必须理解企业经营、财务报表、行业周期和监管要求。因此，这一岗位非常适合讨论科技如何改善金融工作。

信贷风险分析师的日常工作通常包括以下几类。第一，收集并审查借款人的基础资料，例如营业执照、公司章程、财务报表、纳税记录、银行流水、征信报告、购销合同和担保材料。第二，分析企业的经营情况和财务状况，包括收入真实性、毛利率变化、资产负债率、现金流、应收账款质量和短期偿债能力。第三，评估行业风险和区域风险，例如某个行业是否处于下行周期，原材料价格、汇率、政策变化是否会影响企业盈利。第四，设计或复核授信方案，包括贷款额度、期限、利率、还款方式、抵押质押物和保证措施。第五，撰写风险审查报告，把复杂材料转化为可以供审批委员会理解和决策的意见。第六，在贷款发放后进行贷后监测，观察企业经营是否恶化、抵押物价值是否下降、是否出现逾期或资金挪用等迹象。

（二）岗位工作中可能遇到的具体问题

首先是信息量大且分散。一个企业客户的授信材料可能来自银行内部系统、客户提交文件、第三方征信平台、工商司法公开信息、行业报告和监管政策。不同材料格式不同、时间不同、可信度不同。分析师如果只靠人工查阅，很容易耗费大量时间在资料整理上，真正用于判断风险的时间反而被压缩。

其次是财务信息存在“看得见数字，看不清真实经营”的问题。企业财务报表提供了资产、负债、收入、利润等数据，但这些数据不一定完全反映经营质量。例如利润增长可能来自一次性收益，应收账款增长可能隐藏回款压力，存货增长可能意味着销售放缓，银行流水与收入规模不匹配也可能说明收入真实性不足。分析师需要把报表数字、合同、流水、行业情况放在一起看，这对经验要求很高。

第三是政策和合规要求更新快。银行信贷受到监管政策、内部授信制度、行业准入规则和风险偏好约束。某些行业在特定时期可能被限制授信，某些担保方式可能需要满足额外条件。分析师如果没有及时掌握最新制度，可能造成审批意见不合规，甚至引发监管风险。

第四是风险预警不够及时。许多信用风险不是突然发生的，而是提前在经营数据、舆情、司法信息、交易行为中出现信号。例如企业被频繁起诉、主要客户流失、资金流水异常、抵押物重复担保、实际控制人失联等，都是潜在风险。但这些信息分散在不同系统中，如果没有自动化监测，分析师往往只能在逾期后才发现问题。

第五是报告写作和沟通压力大。信贷风险分析师不仅要发现风险，还要把判断写清楚。审批人员希望看到结论明确、依据充分、条理清楚的报告；客户经理希望流程高效；监管和内审部门要求可追溯。大量重复性写作会占用分析师时间，而且不同分析师的报告质量差异也会影响审批效率。

（三）科技如何帮助解决这些问题

第一，可以建设“信贷知识库+动态 RAG 助手”。银行把授信政策、监管规定、行业准入标准、产品制度、历史审查案例和常见风险提示整理成内部知识库，再使用类似 DRAGIN 的动态检索增强生成方法辅助分析师工作。当分析师输入“某光伏制造企业申请流动资金贷款，关注哪些风险”时，系统不应只给普通常识，而应主动检索本行制造业授信政策、最新行业风险提示、该客户历史授信记录和相关监管文件。系统回答时还应标明依据来自哪份制度、哪一条款、哪一份客户材料。

第二，可以用文档智能技术提高资料整理效率。企业授信材料中有大量 PDF、扫描件和表格，人工录入容易出错。通过 OCR、表格识别、信息抽取和自动校验，系统可以从财务报表中提取关键科目，从合同中识别交易对手和金额，从担保文件中抽取抵押物信息，再与银行内部数据进行比

对。例如系统可以自动提示“营业收入增长 30%，但经营性现金流下降”“前五大客户集中度过高”“抵押物评估日期已超过有效期”等问题。这样分析师不用从零开始翻材料，而是把精力集中在风险判断上。

第三，可以建立信用风险预警模型。银行可以结合企业历史还款记录、账户流水、征信变化、司法诉讼、舆情信息、行业指标和宏观数据，构建风险评分和预警模型。机器学习模型擅长从大量历史样本中发现模式，例如某些交易行为变化可能预示资金链紧张，某些财务指标组合可能对应较高违约概率。但模型不能只给一个分数，还应给出可解释原因，例如“应收账款周转下降”“短期债务占比上升”“新增被执行记录”。这能够帮助分析师更快判断哪些客户需要重点跟踪。

第四，可以用知识图谱识别关联风险。很多企业风险不是单个主体本身暴露出来的，而是通过关联方传导。例如借款企业与担保企业实际控制人相同，或者多个客户之间存在循环交易、交叉担保、同一抵押物重复融资等情况。知识图谱可以把企业、股东、实际控制人、担保人、交易对手、司法案件和抵押物连接起来，让分析师看到“关系网络”。在此基础上，系统可以自动发现隐性关联、异常资金流和担保圈风险。

第五，可以用大模型辅助生成报告，但必须坚持人机协同。系统可以根据已核验材料自动形成报告初稿，包括客户概况、财务分析、主要风险、缓释措施和审批建议。分析师再进行修改和判断，补充对企业经营真实性、行业趋势和管理层能力的理解。这样既能提高效率，又能避免把模型输出当作最终结论。尤其是涉及授信额度、风险分类、贷后处置等重要事项时，人仍然应当承担最终责任。

第六，科技应用本身也要纳入风险管理。银行不能因为引入 AI 就忽视新的风险。系统需要控制数据权限，防止客户隐私泄露；需要记录检索和生成日志，便于审计；需要定期测试模型是否存在偏差、幻觉和错误引用；需要设置人工复核机制，避免模型建议直接决定贷款结果。巴塞尔委员会关于金融数字化的讨论也提醒金融机构，人工智能、云计算、开放银行等技术在提高效率的同时，会带来运营风险、声誉风险和系统性关联风险。因此，金融机构使用 AI 的正确方式不是“让技术替代风控”，而是“让技术增强风控，并让技术本身接受风控”。

三、结论

总体来看，DRAGIN 论文讨论的动态检索增强生成技术，抓住了大语言模型商业落地中的一个关键问题：模型不仅要能生成答案，更要知道什么时候需要外部证据、应该检索什么证据、如何把证据组织成可靠回答。对于金融行业而言，这一点尤其重要。金融业务高度依赖事实、数据、制度和责任链条，不能接受没有来源的“流畅表达”。在商业银行信贷风险分析师岗位中，科技可以帮助解决资料分散、政策更新快、风险预警滞后、报告写作重复等问题，但它不能替代人的专业判断。未来更合理的方向，是把动态 RAG、文档智能、风险模型和知识图谱结合起来，形成一个可检索、可解释、可审计的人机协同风控系统。只有这样，人工智能才能真正从“会聊天的工具”变成“能支撑金融决策的基础设施”。

参考文献

- [1] Su W., Tang Y., Ai Q., Wu Z., Liu Y. DRAGIN: Dynamic Retrieval Augmented Generation based on the Real-time Information Needs of Large Language Models. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics, 2024: 12991-13013. DOI: 10.18653/v1/2024.acl-long.702. URL: <https://aclanthology.org/2024.acl-long.702/>.
- [2] Prospects.ac.uk. Financial risk analyst job profile. Written by Graduate Futures Institute editors, June 2025. URL: <https://www.prospects.ac.uk/job-profiles/financial-risk-analyst/>.
- [3] Basel Committee on Banking Supervision. Digitalisation of finance. Bank for International Settlements, May 2024. URL: <https://www.bis.org/bcbs/publ/d575.htm>.
- [4] Reuters. Digitalisation of banking creates new risks, says global watchdog. 16 May 2024. URL: <https://www.reuters.com/business/finance/digitalisation-banking-creates-new-risks-says-global-watchdog-2024-05-16/>.

附：与人工智能对话记录提交提示